

Чекпоинт 5

Нелинейные ML-модели

Команда 23

Участники:

Боева Полина

Бородачев Сергей

Герилович Илья

Чаплыгина Арина

Руководитель:

Макарова Мария

Данные

Kaggle Dota 2 Pro League Matches 2016-2025

Использовались данные матчей профессиональных лиг
2023-2024 года, включающие:

- Статистику игроков (убийства, смерти, ассисты, золото, опыт и другие показатели)
- Метаданные матчей (время, продолжительность, победитель и другие)
- Информацию о командах (состав, Radiant и Dire)

Целевая переменная: **radiant_win**




Рис 1. Структура данных на Kaggle

Методика расчёта агрегированной статистики

1. **Агрегация статистик `account_id` по предыдущим матчам:** *previous_{}_avr* - числовые переменные, рассчитанные для каждого `account_id` с помощью скользящего среднего
2. **Агрегация статистик по командам:** *'min/max/mean_previous_{}_avr'* - числовые переменные, рассчитанные для каждого `match_id` на основе данных о предыдущих матчах `account_id`, участников матча

Линейные модели

Классификатор	Гиперпараметры	Accuracy	F1 Score	ROC-AUC
Logistic Regression	max_iter=500	0.591	0.621	0.632
Logistic Regression (только на колонках с mean)	solver='saga', penalty='l1', max_iter=100, C=100	0.597	0.629	0.643
Logistic Regression	solver='liblinear', penalty='l1', max_iter=100, class_weight=None, C=0.01	0.586	0.609	0.631
Linear Discriminant Analysis	solver='svd', priors=[0.3, 0.7], n_components=1	0.527	0.680	0.633

Feature Engineering

1. **Агрегация статистик hero_name по предыдущим матчам:** *previous_{}_avr_heroes*- числовые переменные, рассчитанные для каждого hero_name с помощью скользящего среднего
2. **Агрегация статистик по командам:** *'previous_{}_avr_heroes_team_mean'* - числовые переменные, рассчитанные для каждого match_id на основе данных о статистике игроков на hero_name за предыдущие матчи
3. **Новые переменные как разница статистик команд:** *previous_{}_avr_team1_mean - previous_{}_avr_team2_mean*

Методы снижения размерности

Для различных вариантов подвыборок переменных (данные до Feature Engineering, данные с разными наборами фичей) были протестированы следующие методы снижения размерности:

1. PCA: для объяснения 95% дисперсии оставили 9 компонент. Это не принесло улучшения качества модели, но в среднем осталось на уровне других моделей.
2. LDA: снижение размерности до $n-1$, n - количество классов, в случае бинарной классификации до 1. Не дает улучшения метрики относительно CatBoost на всех данных, но по всем метрикам превосходит PCA.
3. FeatureSelector from AutoFeat: автоматический отбор оптимального количества признаков. Показал схожие результаты с CatBoost на всех данных, кратно снизив количество признаков.

Нелинейные модели

Классификатор	Гиперпараметры	Accuracy	F1 Score	ROC-AUC
Support Vector Classifier (SVC)	probability=True, class_weight='balanced'	0.597	0.629	0.631
Decision Tree Classifier	class_weight='balanced'	0.529	0.533	0.529
Random Forest Classifier	class_weight='balanced'	0.581	0.594	0.615
CatBoost Classifier		0.599	0.609	0.647
CatBoost Classifier PCA		0.58	0.582	0.626
CatBoost Classifier LDA		0.58	0.62	0.631
CatBoost Classifier diff		0.592	0.605	0.649
CatBoost Classifier diff	'iterations': 468, 'depth': 6, 'learning_rate': 0.038, 'l2_leaf_reg': 1.76, 'border_count': 207, 'one_hot_max_size': 2	0.592	0.614	0.645
CatBoost Classifier Autofeat		0.593	0.607	0.648
CatBoost Classifier heroes		0.598	0.607	0.65

Применение AutoML

model_id	auc	logloss	aucpr	mean_per_class_error	rmse	mse
GBM_1_AutoML_1_20250314_184153	0.634268	0.659323	0.643694	0.461959	0.483819	0.234081
GBM_5_AutoML_1_20250314_184153	0.633786	0.659525	0.641943	0.457345	0.483842	0.234103
GBM_2_AutoML_1_20250314_184153	0.633212	0.659527	0.642367	0.448774	0.483907	0.234166
GBM_grid_1_AutoML_1_20250314_184153_model_2	0.63311	0.660274	0.640614	0.455102	0.484159	0.23441
GBM_3_AutoML_1_20250314_184153	0.632799	0.660021	0.641563	0.4565	0.484103	0.234356
GBM_grid_1_AutoML_1_20250314_184153_model_3	0.632563	0.659946	0.641253	0.461117	0.48406	0.234314
DeepLearning_grid_1_AutoML_1_20250314_184153_model_1	0.630908	0.667925	0.637844	0.464542	0.48633	0.236517
GLM_1_AutoML_1_20250314_184153	0.629999	0.662199	0.636851	0.460804	0.484982	0.235208
XGBoost_3_AutoML_1_20250314_184153	0.629799	0.663583	0.638036	0.465116	0.485648	0.235854
GBM_4_AutoML_1_20250314_184153	0.628035	0.663001	0.637028	0.465101	0.485459	0.23567

Лучшее значение на тестовых данных:

ROC-AUC - 0.63

Выводы

1. Лучшее значение ROC-AUC - 0.65. CatBoost с признаками после Feature Engineering.
2. Подбор гиперпараметров, уменьшение размерности либо не улучшают метрику, либо делают это незначительно.
3. Необходимо доработать датасет или провести более продвинутый feature engineering, на данный момент работа с признаками не дает существенное прироста качества метрики.
4. Логистическая регрессия дает схожие результаты с CatBoost при уменьшении размерности данных (PCA) до 65 компонент с сохранением 95% дисперсии.
5. При использовании AutoML (H2O) также не удалось улучшить метрику. ROC-AUC - 0.63 (лучшая модель - CatBoost).